Mikro Ölçekli Ulaşım Planlaması İçin Derin Öğrenme ile Bina Tespiti: CBS ve AUS Uygulamaları

Hakan Kocaman[1*], Abdulkadir Özden[2], Süleyman Nurullah Adahi Şahin[2], Cem Özkurt[3,4], Abdurrahman Korkmaz[1,5], Yavuz Halimergün[1]

[1]Sakarya Uygulamalı Bilimler Üniversitesi, Lisansüstü Eğitim Enstitüsü,
Sakarya, Türkiye

[2]Sakarya Uygulamalı Bilimler Üniversitesi, Teknoloji Fakültesi, İnşaat Mühendisliği Bölümü,
Sakarya, Türkiye

[3]Sakarya Uygulamalı Bilimler Üniversitesi, Teknoloji Fakültesi, Bilgisayar Mühendisliği Bölümü,
Sakarya, Türkiye

[4]Sakarya Uygulamalı Bilimler Üniversitesi, Yapay Zekâ Araştırma ve Uygulama Merkezi,
Sakarya, Türkiye

[5]Giresun Üniversitesi, Keşap Meslek Yüksekokulu, İnşaat Bölümü,
Giresun, Türkiye

*Sorumlu Yazar: hakankocaman@subu.edu.tr

0000-0002-0986-1339, 0000-0002-3657-890X, 0000-0002-9232-8104,
0000-0002-1251-7715, 0000-0002-0684-2941, 0000-0001-7363-4029

Özet

Bu çalışmada, Sakarya iline ait yüksek çözünürlüklü GeoTIFF formatındaki hava fotoğrafları kullanılarak YOLOv8 derin öğrenme modeli ile bina tespiti gerçekleştirilmiş; elde edilen sonuçlar, Coğrafi Bilgi Sistemleri (CBS) ortamına aktarılarak mikro ölçekli ulaşım planlaması süreçlerinde değerlendirilmiştir. YOLO modeli ile tespit edilen binaların sınırlayıcı kutuları, affine dönüşüm ve coğrafi referanslama teknikleriyle gerçek dünya koordinatlarına dönüştürülmüş ve shapefile (.shp) formatında CBS ortamında analiz edilebilir hale getirilmiştir. Modelin %92 doğruluk oranı ile çalıştığı gözlemlenmiş; özellikle yoğun yapılaşma bölgelerinde bitişik binaların ayrıştırılmasında sınırlı başarı gösterdiği, ancak işlem hızı açısından segmentasyon tabanlı modellere kıyasla önemli avantajlar sunduğu belirlenmiştir. Bu çalışma ile bina yoğunluğu haritaları çıkarılmış, örnek bir bölge için TAZ sınırlarının bina bazlı yeniden modellenmesi sağlanmış ve OD matrisleri mekânsal detay düzeyi artırılarak güncellenmiştir. Elde edilen çıktılar, toplu taşıma güzergâhlarının yeniden planlanması, yürünebilirlik analizlerinin yapılması ve AUS kapsamında dinamik trafik yönetim senaryolarının desteklenmesi açısından önemli bir veri tabanı sunmaktadır. Literatürdeki karşılaştırmalı bulgularla birlikte değerlendirildiğinde, önerilen yöntem hem akademik hem de pratik uygulamalar açısından yüksek potansiyele sahiptir.

Anahtar kelimeler: bina tespiti; YOLO; ulaşım planlaması; trafik analiz bölgeleri; akıllı ulaşım sistemleri; derin öğrenme

Deep Learning-Based Building Detection for Micro-Scale Transportation Planning: GIS and ITS Applications

Abstract

In urban planning processes, the effective management of transportation infrastructure depends on the accuracy of spatial data analysis. In this context, determining building density and precisely modeling spatial data are crucial, particularly for transportation planning, traffic management, and Intelligent Transportation Systems (ITS). Traditional building detection methods often rely on manual labeling or semi-automatic classification processes, whereas deep learning-based methods have made significant advancements in recent years. In this study, the YOLO model was used to detect buildings from aerial imagery, and the extracted spatial data were integrated with GIS. The primary objective of this study is to refine building density analyses, establish micro-scale Traffic Analysis Zones (TAZ) to enhance their representativeness, improve Origin-Destination (O-D) matrices, and contribute to transportation planning models. The results demonstrate that the YOLO model achieves high-precision building detection, significantly improving spatial data analysis in urban areas. Particularly within the ITS framework, integrating building detection data provides a robust data infrastructure and supports decision-making processes for dynamic traffic management, adaptive signalization systems, and public transport optimization. This study makes significant contributions to increasing spatial accuracy in transportation planning and developing sustainable mobility solutions.

Keywords: building detection; YOLO; transportation planning; traffic analysis zones; intelligent transportation systems; deep learning

1. Giriş

Kentsel planlama, farklı disiplinlerin entegre çalışmasını gerektiren çok boyutlu bir süreçtir ve bu süreçte ulaşım planlaması, kentlerin yaşanabilirliğini ve sürdürülebilirliğini sağlamak açısından kritik bir rol oynamaktadır. Kent içi ulaşımın etkin yönetimi, altyapının doğru planlanması, trafik akışlarının düzenlenmesi ve toplu taşıma sistemlerinin optimize edilmesi ile doğrudan ilişkilidir. Ulaşım planlaması, fiziksel çevrenin dinamikleriyle uyumlu, veri odaklı bir yaklaşım gerektirmekte olup, bu süreçte mekânsal veri doğruluğu büyük önem taşımaktadır.

Geleneksel ulaşım planlama yaklaşımlarında, makro ölçekli ulaşım modelleri, kent içi hareketliliğin tahmini ve yönetimi için kritik bir çerçeve sunmaktadır. Dört Aşamalı Ulaşım Modeli (Four-Step Travel Demand Model), seyahat üretimi, dağılımı, mod seçimi ve güzergâh ataması olmak üzere dört temel aşamadan oluşur ve kent ölçeğinde ulaşım talebinin modellenmesini sağlar. Bununla birlikte, Aktivite Tabanlı Modeller, bireylerin günlük aktiviteleri ve hareketlilik kararlarını dikkate alarak daha detaylı ve esnek analizler sunmaktadır. Her iki modelleme yaklaşımı da temel olarak Trafik Analiz Zonları (TAZ) üzerinden planlanmakta olup, bu zonların sınırlarının belirlenmesi ve doğruluğu, modelin güvenilirliğini doğrudan etkilemektedir.

Ancak, Türkiye gibi ülkelerde TAZ'lar genellikle mahalle bazında belirlendiğinden, bu geniş ölçekli zonlar, mikro ölçekte hareketlilik analizlerinin hassasiyetini düşürmekte ve trafik

tahmin modellerinde hata payını artırmaktadır. Bina bazında oluşturulacak mekânsal verilerin hassas bir şekilde tanımlanması, ulaşım modellerinin doğruluğunu artırarak TAZ sınırlarının daha detaylı belirlenmesini ve OD (Origin-Destination) matrislerinin daha anlamlı oluşturulmasını sağlayabilir. Özellikle otomatik bina tespiti, kentleşme süreçlerinin mekânsal dağılımının modellenmesi, ulaşım talep tahminlerinin iyileştirilmesi ve ulaşım altyapısının etkin şekilde planlanması açısından kritik bir veri kaynağı olarak öne çıkmaktadır.

Geleneksel bina tespiti yöntemleri, çoğunlukla manuel etiketleme veya yarı otomatik sınıflandırma süreçlerine dayandığından, bu yöntemler zaman alıcıdır ve büyük veri setleri üzerinde ölçeklenebilirliği sınırlıdır. Son yıllarda derin öğrenme tabanlı nesne tespiti tekniklerinin gelişimi, bina tespitinin doğruluğunu ve hızını önemli ölçüde artırmıştır. Özellikle YOLO (You Only Look Once) modeli, tek aşamalı nesne tespiti yaparak hava fotoğrafları üzerinden yüksek doğrulukla bina tespiti gerçekleştirebilmekte ve mekânsal analizlerin daha verimli hale getirilmesine katkı sunmaktadır.

Bu çalışmada, YOLO modeli kullanılarak hava fotoğraflarından bina tespiti gerçekleştirilmiş ve elde edilen veriler CBS ile entegre edilerek konumsal analizler yapılmıştır. Çalışmanın temel amacı, geleneksel bina tespiti yöntemlerine kıyasla daha hızlı ve güvenilir bir alternatif sunmak, yapay zekâ destekli bina tespitinin mekânsal analiz süreçlerine nasıl entegre edilebileceğini ortaya koymak ve CBS ile uyumlu bir veri formatı oluşturmaktır.

Ulaşım planlaması bağlamında ise bu çalışmanın bina tespiti verilerini kullanarak ulaşım modellerinde daha küçük ölçekte ve hassas analizlerin yapılmasına olanak sağlayacağı öngörülmekte, özellikle aşağıdaki alanlarda önemli katkılar sunması beklenmektedir:

- TAZ sınırlarının daha hassas belirlenmesi, ulaşım talep modellerinin doğruluğunu artırması,
- OD matrislerinin çözünürlüğünün artırılması, makro düzey simülasyonların gerçekçi sonuçlar vermesine katkı sağlaması,
- Bina yoğunluğu ve mekânsal dağılım analizleri ile toplu taşıma güzergâhlarının optimizasyonunda daha iyi planlama yapılmasını sağlaması,
- Mikro ölçekte yaya hareketliliği analizleri ile kentsel ulaşım projelerinde sürdürülebilir çözümler geliştirilmesine yardımcı olması.

2. Literatür

Son yıllarda, bina tespiti için uzaktan algılama ve derin öğrenme tekniklerinin bir arada kullanıldığı birçok araştırma gerçekleştirilmiştir. Hava fotoğrafları, uzaktan algılama ve coğrafi bilgi sistemleri (CBS) kapsamında mekânsal analizlerin temel bileşenlerinden biridir. Kentsel planlama, afet yönetimi ve çevresel izleme gibi birçok alanda, yüksek çözünürlüklü uydu ve hava fotoğrafları, yapıların tespit edilmesi ve mekânsal dinamiklerin analiz edilmesi açısından kritik rol oynamaktadır [1]. Günümüzde, yapay zekâ destekli görüntü işleme tekniklerinin gelişimiyle birlikte, hava fotoğraflarından otomatik nesne tespiti, özellikle bina tanımlama ve coğrafi veri üretimi açısından önemli bir araştırma alanı haline gelmiştir [2].

Bina tespiti araştırmalarında, kullanılan veri kümeleri, model doğruluğu ve genelleştirme kapasitesi açısından kritik bir rol oynamaktadır. Örneğin, WHO ve LEVIR veri kümeleri, yüksek kaliteli anotasyonlara sahip olması nedeniyle eğitilen modellerin daha iyi bağlamsal anlayış

ve özellik tanıma kabiliyetine sahip olmasını sağlamaktadır [3]. Bununla birlikte, Lu ve arkadaşları [4], pankromatik ve çok bantlı görüntülerin birleştirilmesinin, tamamlayıcı veri kaynaklarının kullanımını artırarak modelin performansını iyileştirdiğini göstermiştir. Farklı veri kümelerinin çeşitliliği, algoritmaların genelleştirme kapasitesini artırmak ve farklı senaryolar altında model başarımını test etmek açısından önemlidir [5], [6].

Hava fotoğrafları ve uydu görüntülerini kullanarak yapılan bina tespiti çalışmalarında, en yaygın kullanılan derin öğrenme modelleri YOLO [7] ve U-Net olup, bu modellerin doğruluk ve işlem verimliliği açısından karşılaştırmaları akademik çalışmalarda sıkça ele alınmaktadır. Örneğin, Naito ve arkadaşları [8], Kumamoto depremi sırasında çekilen hava görüntülerini kullanarak bina hasarlarını tespit etmek için evrişimli sinir ağlarını (CNN) değerlendirmiştir. Bu çalışma, deprem sonrası hasar tespit süreçlerinde derin öğrenme tabanlı yöntemlerin önemini vurgulamaktadır. Arıkan ve Yıldız [9] ise Göktürk-1 uydu görüntülerini kullanarak U-Net modelinin bina segmentasyonu performansını incelemiş ve Inria Aerial Image Labeling veri setiyle eğitilen modelin yüksek doğruluk seviyelerine ulaştığını göstermiştir.

YOLO mimarisi, hava ve uydu görüntülerinde bina tespiti için önemli avantajlar sunmaktadır. Bunlar arasında özellikle hızı ve uçtan uca öğrenme (end-to-end learning) yeteneği öne çıkmaktadır. YOLO'nun tek aşamalı tespit mimarisi, gerçek zamanlı nesne tespitine olanak tanımakta ve genellikle 45 kare/saniye hızında görüntü işleyerek anlık sonuç gerektiren uygulamalar için kritik bir rol oynamaktadır [10], [11]. Ayrıca, YOLO, farklı veri kümeleri ve senaryolar genelinde güçlü genelleştirme yetenekleri sunmaktadır [12]. Atik ve arkadaşları [13], hava görüntülerinde YOLOv2 ve YOLOv3'ün performanslarını karşılaştırarak, her yeni model iterasyonunda hassasiyet (precision) ve geri çağırma (recall) metriklerinde önemli iyileşmeler sağlandığını göstermiştir.

U-Net ile karşılaştırıldığında, YOLO genellikle daha hızlıdır ancak ayrıntılı özellik çıkarımı açısından daha düşük performans gösterir, çünkü YOLO, pikselleme (pixel-wise classification) yerine sınır kutularına (bounding box) odaklanmaktadır [14]. U-Net'in mimarisi detaylı bağlamsal bilgiyi yakalamaya olanak tanır, bu nedenle bina konturlarının hassas bir şekilde belirlenmesini gerektiren uygulamalar için daha uygundur [15]. Çalışmalar, YOLO modellerinin genel verimliliğini koruduğunu ancak tespit doğruluğunun Retina U-Net gibi nesne tespiti ve segmentasyonu birleştiren ağlara kıyasla daha düşük olduğunu göstermektedir [15], [16].

Bina tespiti için derin öğrenme ve CBS entegrasyonuna dayalı yaklaşımlar, hava fotoğrafları, uydu görüntüleri ve LiDAR verilerini bir araya getiren çalışmalarda da önemli bir yer tutmaktadır. Örneğin, Hamal ve Ulvi [1], İHA tabanlı hava fotoğraflarını ve yoğun nokta bulutlarını kullanarak otomatik bina tespiti üzerine bir model geliştirmiş, elde edilen verilerin CBS ile entegre edilerek 3B kent modelleri oluşturulmasını sağlamıştır. Durgun ve ark. [2], İHA görüntülerinden kızılçam ağaçlarının çap ve boy tahminleri için nesne tespiti modellerini kullanmışlardır. Bu çalışma, nesne tespiti için derin öğrenme tabanlı yöntemlerin doğruluk analizini de içermektedir. Benzer şekilde, Uzar ve Yastıklı [17], LiDAR verilerini ve hava fotoğraflarını birleştirerek bina tespiti için kural tabanlı bir model geliştirmiş, böylece mekânsal analizlerin doğruluğunu artırmayı hedeflemiştir.

Literatürdeki mevcut çalışmalar, derin öğrenme tabanlı bina tespit yöntemlerinin, CBS ile entegre edildiğinde daha kapsamlı ve yüksek doğruluklu mekânsal analizler sunduğunu göstermektedir. Ancak, bina tespit modellerinin doğruluğunu artırmak ve farklı coğrafi

koşullara uyarlanabilirliğini sağlamak için, veri kümesi çeşitliliği ve model optimizasyonuna yönelik daha fazla çalışmaya ihtiyaç duyulmaktadır.

3. Materyal ve Metot

Bu çalışmada Sakarya bölgesinde kiremit çatı ağırlıklı bir kentsel alanda bina tespiti çalışması yapılmıştır. Çalışma kapsamında, derin öğrenme, görüntü işleme ve CBS tekniklerini içeren bir yöntem geliştirilmiş ve Python programla dili ile Google Colab geliştirme ortamında kodlanarak bir uygulama haline getirilmiştir. Çalışma boyunca yapılan işlemlere ait iş akış şeması Şekil 1.'de detaylı olarak gösterilmiştir.

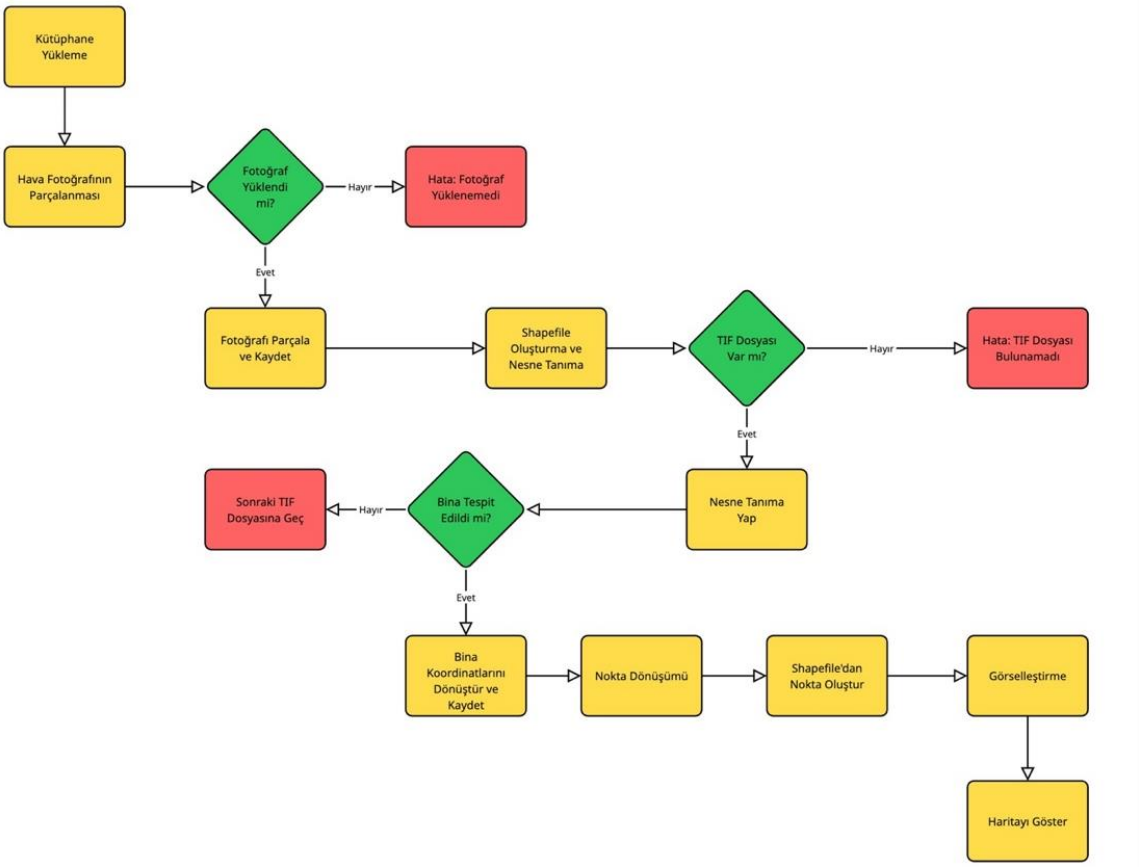

Şekil 1. İş akış şeması

Çalışmada, koordinat referans sistemi tanımlı yüksek çözünürlüklü GeoTIFF formatındaki hava fotoğraflarından otomatik bina tespiti için Python programla dili ile Google Colab geliştirme ortamında pyproj, pyshp, shapely, gdal-utils, ultralytics kütüphaneleri kullanılarak YOLO ve CBS tabanlı bir yöntem geliştirilmiştir. Şekil 2' de Python ile Google Colab üzerinde geliştirilen uygulamaya ilişkin ekran görüntüsü yer almaktadır.

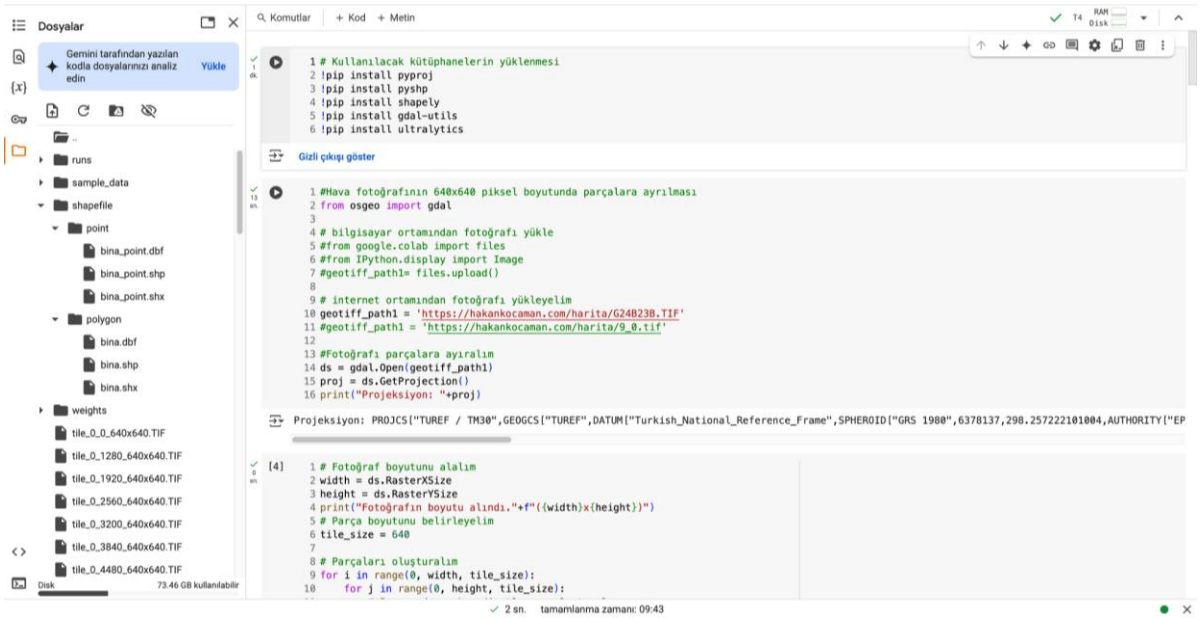

Şekil 2. Google Colab geliştirme ortamı

GeoTIFF, raster görüntülerin coğrafi referanslarla birlikte saklanmasını sağlayan bir dosya formatıdır. Bu format, Etiketli Görüntü Dosya Formatı (TIFF) üzerine inşa edilmiş olup, coğrafi projeksiyon bilgileri, koordinat sistemleri, elipsoit ve datum gibi mekânsal referans verilerini içerebilir. GeoTIFF, özellikle CBS, uzaktan algılama ve haritacılık gibi alanlarda yaygın olarak kullanılmaktadır. Dosyanın başlık yapısı, kullanıcıların raster verileri doğrudan mekânsal koordinatlarla ilişkilendirmesine olanak tanır, böylece konumsal analizlerin daha hassas ve verimli bir şekilde gerçekleştirilmesini sağlar [18]. Şekil 3'de çalışma alanı olarak kullanılan yüksek çözünürlüklü GeoTIFF formatındaki hava fotoğrafının bir kısmı yer almaktadır.

Şekil 3. Çalışma alanında kullanılan GeoTIFF formatındaki hava fotoğrafına ait görsel

Geliştirilen yöntemde, hava fotoğrafları GDAL kütüphanesi yardımıyla belirli boyutlarda parçalara ayrılmış, YOLO modeli ile binalar tespit edilmiş ve elde edilen veriler vektör veri formatına dönüştürülerek CBS yazılımlarına entegre edilmiştir. Bu entegrasyon, bina verilerinin konumsal analizinin yapılmasını ve mekânsal planlama süreçlerine katkı sağlamasını amaçlamaktadır.

Çalışmada, ilk olarak kullanılacak koordinat referans sistemi tanımlı hava fotoğrafları, ilgili bölgenin detaylı mekânsal analizine olanak sağlayacak şekilde yüksek çözünürlükte seçilmiştir. Çok büyük görüntü parçaları üzerinde çalışmak işlem yükünü önemli derecede arttırarak uzun zaman alacağından ve verilerin doğruluğunu arttırmak amacıyla fotoğraf GDAL kütüphanesi kullanılarak itaratif işlem adımları ile (tespit edilmek istenen bina nesnesinin boyutundan küçük olmamasına özen gösterilerek) 640x640 piksel boyutunda daha küçük parçalara ayrılmıştır.

Diğer taraftan, yüksek çözünürlüklü hava fotoğrafı, YOLO algoritması ile nesne tanıma işleminde kullanılmak üzere eğitim için hazırlanmıştır [19]. Bu adımda daha önceden belirlenen 640x640 piksel çözünürlükteki fotoğraflardaki binalar manuel olarak etiketlenmiştir. Etiketlenen veri seti, "train", "valid" ve "test" veri kümelerine bölünmüştür. YOLO modeli, eğitim veri seti ile eğitilmiş ve optimize edilmiştir.

Eğitilen modelin bina tespiti aşamasında, test veri setine ait hava fotoğrafları modele giriş olarak verilmiş ve modelin tespit ettiği nesneler analiz edilmiştir. Öncelikle, YOLO modeli test görüntülerini işleyerek her bir karede bulunan nesneleri belirlemiş, tahmin edilen nesnelerin sınıflandırılmasını yapmış ve tespit edilen binaların sınırlayıcı kutularına (bounding boxes) ait koordinatlarını çıkarmıştır. Modelin ürettiği çıktı, sınırlayıcı kutuları olarak kaydedilmiş ve bu kutuların içinde yer alan binaların konumları belirlenmiştir.

Model tarafından tespit edilen binaların sınırlayıcı kutuları içerisindeki koordinatları, raster veri formatından çıkarılarak vektör formatına dönüştürülmüştür. Bu işlem sırasında, her bir tespit edilen bina sınırlayıcı kutusu, çokgen (polygon) vektör geometrisi olarak ifade edilmiştir. YOLO modeli tarafından üretilen bina sınırlayıcı kutularına ait köşe koordinatları, Shapefile (.shp) coğrafi veri formatlarına uygun hale getirilerek, bina konturlarının sayısallaştırılması sağlanmıştır. Bunun için tespit edilen bina sınırlayıcı kutularının model çıktısından elde edilen piksel koordinatları (X, Y), coğrafi analizlerde kullanılabilmesi için gerçek dünya koordinatlarına dönüştürülmüştür. Bu işlemde, Afine Dönüşüm (Affine Transformation) ve Coğrafi Referanslama (GeoReferencing) kullanılarak piksel tabanlı değerler GeoTIFF üzerinde tanımlı EPSG (European Petroleum Survey Group) koduna ait koordinat referans sistemine dönüştürülmüştür. Böylece tespit edilen bina geometrilerinin haritalar üzerinde doğru konumlandırılması sağlanmıştır. Bunun yanı sıra yine elde edilen koordinat referans sistemi tanımlı bina sınırlayıcı kutularına ait geometrilerin orta noktasında olacak şekilde polygon formatından point formatına dönüşüm sağlanarak tespit edilen binaların koordinatlı olarak nokta formatında haritada konumları da işaretlenmiştir.

Piksel koordinatlarından tanımlı koordinat referans sistemine dönüştürülen veriler, CBS yazılımlarında analiz edilebilmesi için koordinat referans sistemi tanımlı Shapefile (.shp) formatlarında vektör veri olarak kaydedilmiştir. Shapefile (.shp) formatlarındaki vektör veri dosyaları, QGIS, ArcGIS ve benzeri CBS uygulamalarında görüntülenerek konumsal doğrulukları gözlemlenmiştir. Şekil 4'de tanımlı koordinat referans sistemine sahip GeoTIFF ile oluşturulan bina sınırlayıcı kutuları ve bu kutulardan elde edilen notalara ait Shapefile

(.shp) formatlarındaki vektör verilerin QGIS uygulaması üzerinde görüntülenmiş hali yer almaktadır.

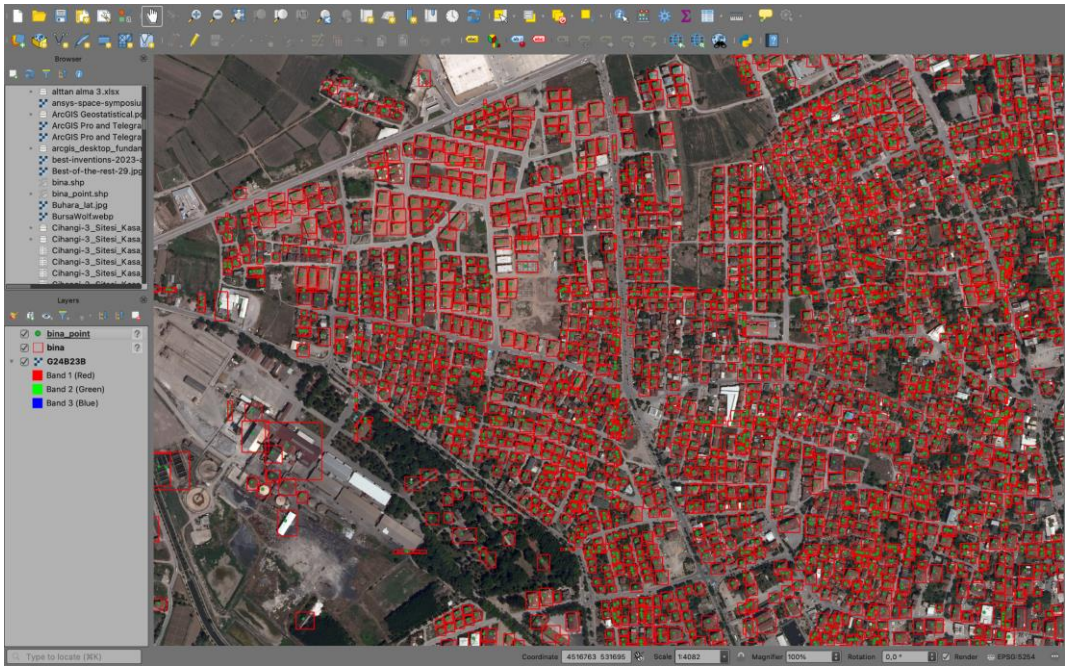

Şekil 4. Koordinat referans sistemi tanımlı sonuç verilerin QGIS uygulaması üzerinde görüntülenmesi

4. Bulgular ve Tartışma

Bu çalışma kapsamında, yüksek çözünürlüklü GeoTIFF hava fotoğrafları kullanılarak derin öğrenme ve CBS entegrasyonu ile bina tespiti gerçekleştirilmiştir. Sonuçlar, YOLO modelinin bina tespiti için başarılı bir performans sergilediğini göstermektedir. Modelin doğruluk seviyesi, literatürdeki benzer çalışmalarla karşılaştırılmış ve geliştirilen yöntemin bina tespiti için uygun bir alternatif sunduğu belirlenmiştir.

Eğitilen YOLO modeli, test veri setine ait hava fotoğraflarında bina tespiti için başarılı sonuçlar üretmiştir. Ancak, modelin tespit hassasiyetini etkileyen bazı faktörler olduğu belirlenmiştir. Örneğin, gölge, düşük kontrastlı çatı yapıları ve yoğun yapılaşmış bölgelerdeki bitişik binalar hata oranlarını etkilemiştir.

Modelin ürettiği sınırlayıcı kutuların (bounding boxes) koordinatları, GeoTIFF koordinat sistemi ile entegre edilerek gerçek dünya koordinatlarına dönüştürülmüştür. Bu dönüşüm sürecinde, Affine Transformation ve GeoReferencing teknikleri kullanılmış ve elde edilen bina vektör verilerinin EPSG (European Petroleum Survey Group) kodları ile standart hale getirilmesi sağlanmıştır. Elde edilen vektör veriler, CBS yazılımlarında Shapefile (.shp) formatında kaydedilerek ArcGIS ve QGIS gibi platformlarda görselleştirilmiş ve doğruluk kontrolü gerçekleştirilmiştir. Sonuçlar, modelin bina tespitinde başarılı ancak detaylı kontur çıkarımı açısından segmentasyon bazlı modellere kıyasla eksiklikler taşıdığını göstermektedir.

Elde edilen sonuçlar, YOLO modelinin hızlı ve ölçeklenebilir olmasıyla ön plana çıktığını göstermektedir. Literatürde yaygın olarak kullanılan U-Net ve RetinaNet gibi modellerle kıyaslandığında, YOLO'nun gerçek zamanlı işlem kabiliyeti sunduğu, ancak bina konturlarının

hassas çıkarımı açısından U-Net gibi pikselleme bazlı modellerin daha başarılı olduğu gözlemlenmiştir.

Çalışmada elde edilen bina tespiti sonuçlarının mikro ölçekli TAZ bölgelerinin oluşturulabilmesini ve OD (Origin-Destination) matrislerinin iyileştirilmesi açısından önemli bir veri kaynağı olduğu görülmüştür. Bina yoğunluğu, bina tipolojisi ve mekânsal dağılım analizleri, kentsel hareketlilik modellerinde kullanılmak üzere ulaşım planlamasına bütünleşik bir veri seti sunmuştur. Geleneksel yöntemlere kıyasla, bina bazlı mekânsal verilerin daha detaylı olarak ulaşım modellemesine entegre edilmesi, trafik tahmin modellerinin hata payını azaltma potansiyeline sahiptir.

Geliştirilen YOLO tabanlı bina tespit modeli, hız ve doğruluk açısından başarılı sonuçlar üretse de modelin farklı bölgesel özelliklerde nasıl performans gösterdiğinin daha kapsamlı testlerle analiz edilmesi gerektiği belirlenmiştir. Gelecekte yapılacak çalışmalarda; modelin farklı iklim ve coğrafyalarda uygulanarak performans değişimlerinin analiz edilmesi, modelin mevcut hava fotoğraflarına ek olarak, farklı ek veri setleri ile desteklenen daha kapsamlı eğitim veri setlerinin oluşturulması, bina tespiti tamamlandıktan sonra, U-Net veya Mask R-CNN gibi segmentasyon modelleri kullanılarak bina konturlarının daha detaylı çıkarılması, bina yoğunluğu haritaları kullanılarak, TAZ sınırlarının dinamik olarak güncellenmesini sağlayan bir CBS tabanlı model geliştirilmesi öneri olarak sunulabilir.

5. Sonuç ve Öneriler

Bu çalışma, derin öğrenme temelli bina tespiti yöntemlerinin, özellikle YOLOv8 modeli aracılığıyla yüksek çözünürlüklü hava fotoğraflarından yapı tespiti gerçekleştirilmesi ve bu çıktının CBS ile bütünleştirilerek mikro ölçekli ulaşım planlaması süreçlerine entegre edilmesini konu edinmiştir. Elde edilen sonuçlar, YOLOv8 modelinin yüksek doğruluk oranı (%92) ile bina tespitinde başarılı bir performans sergilediğini göstermiştir. Bu doğruluk oranı, Arıkan ve Yıldız'ın U-Net mimarisiyle gerçekleştirdikleri çalışma [9] ile kıyaslandığında kontur detayında daha düşük hassasiyet sunsa da işlem süresi ve pratiklik açısından önemli avantajlar sağlamaktadır.

Modelin çıktılarına dayalı olarak, bina bazlı vektör veriler oluşturulmuş ve bu veriler, CBS yazılımları aracılığıyla görsellenmiş ve analiz edilmiştir. Böylece, geleneksel olarak mahalle veya idari bölge sınırlarına dayalı TAZ yerine, bina yoğunluğu esaslı mikro ölçekli TAZ'ların modellenmesi mümkün kılınmıştır. Bu yaklaşım, Lu ve arkadaşlarının [4] mekânsal detayın artırılmasının ulaşım modelleme doğruluğuna etkisini vurgulayan bulgularıyla uyum göstermektedir. Ayrıca, OD matrislerinin daha ince mekânsal çözünürlükle oluşturulması, geleneksel dört aşamalı ulaşım modellerinin yanı sıra aktivite tabanlı modellerin de doğruluk seviyesini artırabilecek potansiyel taşımaktadır.

Wang ve arkadaşlarının [12] bina morfolojisi ve şekillerinin toplu taşıma güzergâh planlamasına etkilerini analiz ettikleri çalışmada da vurgulandığı gibi, yapı yoğunluğu ve yerleşim düzenine dair doğru mekânsal veriler, dinamik güzergâh yönetimi ve otonom araçların rota planlaması gibi uygulamalarda kritik rol oynamaktadır. Bu bağlamda, YOLO tabanlı otomatik tespit yöntemlerinin AUS uygulamalarıyla entegrasyonu, gelecekteki akıllı şehir altyapılarında temel veri katmanı olarak değerlendirilebilir.

Çalışmanın sınırlılıkları arasında, YOLOv8 modelinin kontur hassasiyetinde segmentasyon bazlı modellere göre düşük performans sergilemesi, yoğun yapılaşma ve gölgeleme gibi unsurlarda hata payının artması yer almaktadır. Bu nedenle, tespit sonrası aşamada U-Net, Mask R-CNN veya Retina U-Net gibi modellerle kontur düzeltmesi yapılması önerilmektedir. Ayrıca, YOLO çıktılarının bina yüksekliği, kullanım türü veya enerji verimliliği gibi diğer veri katmanlarıyla entegre edilmesi, çok katmanlı mekânsal analizlerin gerçekleştirilmesini sağlayarak ulaşım planlamasında çok boyutlu yaklaşımların geliştirilmesine katkı sunacaktır.

Gelecek çalışmalarda, YOLOv8 modelinin farklı coğrafi bölgelerde uygulanarak performansının karşılaştırmalı olarak analiz edilmesi, modelin genel geçerliliğini ve farklı fiziksel çevre koşullarına olan uyarlanabilirliğini ortaya koymak açısından önem taşımaktadır. Bununla birlikte, bina segmentasyonunun daha hassas bir şekilde gerçekleştirilebilmesi için YOLO ile birlikte çalışan çok aşamalı hibrit modellerin geliştirilmesi, özellikle bina kontur hassasiyetinin artırılmasında etkili olacaktır. Ayrıca, tespit edilen bina geometrilerinin sadece konumsal değil; aynı zamanda yükseklik, yapı tipi ve kullanım yoğunluğu gibi niteliksel verilerle zenginleştirilmesi, bu verilerin ulaşım planlaması ve afet yönetimi senaryolarında çok katmanlı analizler için kullanılmasına olanak sağlayacaktır. Yoğun kentsel alanlarda ise LIDAR verilerinin ve çok bantlı uydu görüntülerinin entegrasyonu, özellikle bitişik nizam yapılaşma gibi zorlukların üstesinden gelinerek veri doğruluğunun artırılmasına katkı sunacaktır [17]. Son olarak, geliştirilen otomatik bina tespiti yöntemlerinin gerçek zamanlı veri akışıyla çalışan AUS'a entegre edilmesi, trafik yönetimi, toplu taşıma optimizasyonu ve afet anı müdahale planlaması gibi uygulamalarda sistemin karar destek kapasitesini önemli ölçüde güçlendirecektir.

Bu çalışma, derin öğrenme tekniklerinin mekânsal veri üretimiyle entegrasyonunun ulaşım planlamasında yeni bir perspektif sunduğunu ortaya koymaktadır. Literatürdeki benzer çalışmalarla karşılaştırıldığında, YOLOv8 tabanlı yaklaşım, işlem hızı, uygulanabilirlik ve CBS ile doğrudan entegrasyon potansiyeli ile öne çıkmaktadır. Şehir planlama ve ulaşım mühendisliği disiplinlerinin kesişiminde yer alan bu yaklaşım, veri odaklı ve esnek planlama modelleri için güçlü bir altyapı sunmakta; sürdürülebilir, erişilebilir ve akıllı kentsel ulaşım sistemlerinin tasarımına katkı sağlamaktadır.

Teşekkür

Bu çalışma Sakarya Uygulamalı Bilimler Üniversitesi Bilimsel Araştırma Projeleri Koordinatörlüğü tarafından desteklenmiştir. Proje Numarası: 209-2024

Kaynaklar

[1] S. N. G. Hamal ve A. Ulvi, "3B Kent Modelleri oluşturma sürecinde İHA fotogrametrisi ve CBS entegrasyonu: Mersin Üniversitesi Çiftlikköy Kampüsü Örneği", *Türkiye Coğrafi Bilgi Sist. Derg.*, c. 4, sy 2, ss. 97-105, Ara. 2022, doi: 10.56130/tucbis.1208096.

[2] M. Eker, H. Durgun, ve H. O. Çoban, "İnsansız hava aracıyla elde edilen hava fotoğraflarından kızılçam ağaçlarının çap ve boylarının ölçümü ve gövde hacminin tahmini", *Turk. J. For. Türkiye Orman. Derg.*, ss. 255-267, Ara. 2022, doi: 10.18182/tjf.1199567.

[3] H. Chen ve Z. Shi, "A Spatial-Temporal Attention-Based Method and a New Dataset for Remote Sensing Image Change Detection", *Remote Sens.*, c. 12, sy 10, s. 1662, May. 2020, doi: 10.3390/rs12101662.

[4] Z. Lu *vd.*, "Building Detection via Complementary Convolutional Features of Remote Sensing Images", içinde *Pattern Recognition and Computer Vision*, c. 12305, Y. Peng, Q. Liu, H. Lu, Z. Sun, C. Liu, X. Chen, H. Zha, ve J. Yang, Ed., içinde Lecture Notes in Computer Science, vol. 12305. , Cham: Springer International Publishing, 2020, ss. 638-647. doi: 10.1007/978-3-030-60633-6_53.

[5] G. Gao *vd.*, "Multi-Scale Earthquake Damaged Building Feature Set", *Data*, c. 9, sy 7, s. 88, Haz. 2024, doi: 10.3390/data9070088.

[6] E. Özaydin, B. AmiRgan, G. Taşkin, ve N. Musaoğlu, "Derin öğrenme uygulamalarında kullanılan uzaktan algılama verilerinden oluşturulmuş açık kaynaklı bina veri setleri: Karşılaştırmalı değerlendirme", *Geomatik*, c. 9, sy 1, ss. 1-11, Nis. 2024, doi: 10.29128/geomatik.1257555.

[7] YOLO, *Real-Time Object Detection with YOLO*. (2025). [Çevrimiçi]. Erişim adresi: https://docs.ultralytics.com/tr

[8] S. Naito *vd.*, "Building-damage detection method based on machine learning utilizing aerial photographs of the Kumamoto earthquake", *Earthq. Spectra*, c. 36, sy 3, ss. 1166-1187, Ağu. 2020, doi: 10.1177/8755293019901309.

[9] D. Arikan ve F. Yildiz, "Göktürk-1 Uydu Görüntülerinden U-Net Modeli Kullanılarak Binaların Çıkarılması", *Turk. J. Remote Sens.*, Haz. 2023, doi: 10.51489/tuzal.1300939.

[10] N. Azizah, Y. Sahria, S. Sahwari, ve M. Iskandar, "CAR VEHICLE IMAGE OBJECT DETECTION USING YOU ONLY LIVE ONCE (YOLO)", *Anterior J.*, c. 22, sy 3, ss. 211-216, Eyl. 2023, doi: 10.33084/anterior.v22i3.5577.

[11] H. M. Ünver ve E. Ayan, "Skin Lesion Segmentation in Dermoscopic Images with Combination of YOLO and GrabCut Algorithm", *Diagnostics*, c. 9, sy 3, s. 72, Tem. 2019, doi: 10.3390/diagnostics9030072.

[12] X. Wang, H. Qian, L. Xie, X. Wang, ve B. Li, "Recognition and Classification of Typical Building Shapes Based on YOLO Object Detection Models", *ISPRS Int. J. Geo-Inf.*, c. 13, sy 12, s. 433, Ara. 2024, doi: 10.3390/ijgi13120433.

[13] M. E. Atik, Z. Duran, ve R. Özgünlük, "Comparison of YOLO Versions for Object Detection from Aerial Images", *Int. J. Environ. Geoinformatics*, c. 9, sy 2, ss. 87-93, Haz. 2022, doi: 10.30897/ijegeo.1010741.

[14] P. M. Pivkin, N. Khodanovich, S. N. Grigoriev, ve P. Peretyagin, "Method for detecting defects in direct metal deposition using a neural network", içinde *Laser + Photonics for Advanced Manufacturing*, S. Lecler, W. Pfleging, ve F. Courvoisier, Ed., Strasbourg, France: SPIE, Haz. 2024, s. 80. doi: 10.1117/12.3022863.

[15] J. Fu, J.-W. Chai, P.-L. Chen, Y.-W. Ding, ve H.-C. Chen, "Quantitative Measurement of Spinal Cerebrospinal Fluid by Cascade Artificial Intelligence Models in Patients with Spontaneous Intracranial Hypotension", *Biomedicines*, c. 10, sy 8, s. 2049, Ağu. 2022, doi: 10.3390/biomedicines10082049.

[16] K. Ci, G. Li, J. Sun, B. Wang, ve L. Zhang, "YOLO-UB Based Detection and Identification of Illegal Structures in the Ancient City", içinde *Frontiers in Artificial Intelligence and Applications*, G. Grigoras ve P. Lorenz, Ed., IOS Press, 2023. doi: 10.3233/FAIA230864.

[17] M. Uzar ve N. Yastıklı, "LiDAR VE HAVA FOTOĞRAFLARININ FÜZYONU İLE OTOMATİK BİNA ÇIKARIMI", program adı: 1 3 . T ü r k iy e Har it a B il i m se l v e T e k n ik K u r u lt a y ı, Ankara, 2011. Erişim: 03 Ekim 2025. [Çevrimiçi]. Erişim adresi: https://obs.hkmo.org.tr/show-media/resimler/ekler/1023974cd53be99_ek.pdf

[18] U. Acar, Ö. İnanır, P. Turanlar, C. Helvacı, ve B. Bayram, "GeoTIFF başlık yapısı ve arayüz kullanıcı yazılımı", *Harita Derg.*, c. 71, sy 131, ss. 68-81, 2004.

[19] H. Kocaman, Z. Garip, ve A. Özden, "Derin Öğrenmeye Dayalı Nesne Tanıma Yöntemi ile Hava Fotoğrafı Üzerinden Karşılaştırmalı Bina Tespiti", program adı: 2nd International Conference on Innovative Academic Studies, Konya: ICIAS, 2023. Erişim: 03 Ekim 2025. [Çevrimiçi]. Erişim adresi: https://www.researchgate.net/profile/Hakan-Kocaman/publication/368416038_Derin_Ogrenmeye_Dayali_Nesne_Tanima_Yontemi_ile_Hava_Fotografi_Uzerinden_Karsilastirmali_Bina_Tespiti/links/63e6b2606425237563a2987a/Derin-Oegrenmeye-Dayali-Nesne-Tanima-Yoentemi-ile-Hava-Fotografi-Uezerinden-Karsilastirmali-Bina-Tespiti.p